



Metoda hlavních komponent (PCA)

- Principal Component Analysis
- používá se singular value decomposition (SVD)

	Mouse 1	2	3	4	5	6
gene1	10	11	8	3	1	2
gene2	6	4	5	3	2.8	1

gene - variable
mouse - sample

- pokud změříme pouze 1 gen, můžeme data zkrátit na přímku



- pokud změříme 2 geny, můžeme použít 2D graf


- pokud bychom měřili 3 geny, máme 3D graf
- 4 geny $\neq$ 4 dimenze $\rightarrow$ musíme změnit data (cluster)



Postup pro PCA:

- 1) zkrátit data do grafu
- 2) spočítat průměrnou hodnotu pro gen 1 a gen 2
- díky průměru můžeme najít střed dat
- 3) přesunout střed na souřadnici $[0;0]$

(data jsou umístěna relativně)



- 4) nakreslit přímku, která rozdělí data
- začneme random přímkou, pak ji modelujeme tak, aby pasovala co nejlip na data
 - vždy prochází středem $([0;0])$



- projednat dat na random přímku
- a měřit vzdálenosti dat
- a hledat najít přímku, která ty vzdálenosti minimalizuje

- měříme měřené vzdálenosti z projektoraného bodu do středu d

pak to funguje matematicky

- vzdálenost bodů (1-6) od středu je fixní
- když spojíme bod s random přímkou (90°), vytvoří se pravoúhlý Δ

$$a^2 = b^2 + c^2$$

↑
austává
stejně

↑
pokud se b zvětší,
c se musí zmenšit

- PCA - je jednodušší počítat c než b, takže:


potřebujeme najít přímku tak, že maximalizujeme součet umocněných vzdáleností a projektoraných bodů do středu

PC1 - ^{přímka, která} má největší SS vzdálenosti $\sum_{i=1} (d_i)^2 = SS$ (sum of squared distances)
- je to lineární kombinace proměnných

$$\text{Eigenvalue} = \frac{SS(\text{distances for PC1})}{n-1}$$

$$\text{Singular value} = \sqrt{SS(\text{distances for PC1})}$$

PC2 - kolmá přímka na PC1, také prochází středem



- výsledky nám říkají, že gene 2 je 4x důležitější než gene 1

graf PCA - otočíme přímky tak, aby splývaly s osami
(PCA1 = x, PCA2 = y)
PCA2 (17%)

