

METODA HLAVNÍCH KOMPONENT

- Principal Component Analysis
- redukce dimensionalit datového souboru, ale zachování co nejvíce informací
- nalezení nových os (hlavních komponent, PC), podél nichž je variabilita dat co největší
- hlavní komponenty - nové osy, které jsou lineární kombinací původních proměnných
- variabilita - míra rozptylu datových bodů kolem střední hodnoty
- eigenvektory - určují směr komponent
- eigenhodnoty - určují důležitost / velikost komponent
- skalární projekce - projekce datových bodů na nové osy

Princip

- 1) Standardizace dat - každá hodnota by měla mít průměrnou hodnotu 0 a směrodatnou odchylku 1
$$z = \frac{x - \mu}{\sigma}$$
- 2) výpočet kovarianční matice - ukazuje, jak se proměnné vzájemně ovlivňují
$$\Sigma = \frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)(x_i - \mu)^T$$
- 3) výpočet eigenvektorů a eigenhodnot kovarianční matice
- tyto vektory a hodnoty určí nové osy (hlavní komponenty)
- 4) seřazení eigenhodnot - v sestupném pořadí
výběr eigenvektorů, které odpovídají největším eigenhodnotám (to jsou hlavní komponenty, které zachovávají nejvíce info)
- 5) projekce dat na hlavní komponenty

výsledné eigenvektory se používají k transformaci dat do nového prostoru $Y = X \times P$
 Y - transformovaná data
 P - matice vybraných eigenvel.

k čemu to je: redukce dimenzionality, vizualizace, kompresní algoritmus, identifikace důležitých vlastností

FAKTOROVÁ ANALÝZA

- identifikace skrytých struktur (faktorů) v datasetu
- způsob, jak modelovat variability mezi pozorovanými, korelovanými proměnnými a jak redukovat dataset do menšího počtu nekorelovaných proměnných zvaných "faktory"
- faktory - skryté proměnné, které ovlivňují pozorované proměnné
- faktorový náklad - míra, jakou daná pozorovaná proměnná reaguje na skrytý faktor
- kovarianční matice - analýza vztahů mezi proměnnými
- eigenvektory a eigenhodnoty - používají se, podobně jako v PCA, k identifikaci faktorů
- rotace - způsob, jak usnadnit interpretaci faktorů, např. ortogonální (varimax) nebo oblíbená (oblimin)

Princip:

- 1) Specifikace modelu - výchozím bodem je model, který popisuje, jak jsou pozorované proměnné (X) ovlivněny skrytými faktory (F) a chybami (E)
 $X = \Lambda F + E$ (Λ - faktorové náklady)
- 2) Standardizace dat
- 3) výpočet kovarianční matice (stejný vorec jako u PCA)
- 4) výpočet eigenvektorů a eigenhodnot (bereme ty s hodnotou > 1)
- 5) výběr faktorů
- 6) rotace - faktorové náklady se rotují, aby bylo snazší interpretovat

vat, co každý faktor znamená

7) skórování - každé pozorování v původním datasetu je hodnoceno podle toho, jaký má vztah k vybraným faktorům

k čemu to je: identifikace skrytých proměnných v testech osobnosti, segmentace zákazníků podle různých faktorů, analýza rizikových faktorů, ...

DISKRIMINAČNÍ ANALÝZA

- rozlišení mezi 2 a více skupinami na základě jejich charakteristik
- často používaná metoda v klasifikačních problémech, kde je cílem určit, do jaké předdefinované skupiny nové pozorování spadá
 - diskriminační funkce - lineární kombinace charakteristik, která se používá k maximálnímu oddělení skupin
 - priorové pravděpodobnosti - pravděpodobnosti, že náhodně vybrané pozorování patří do jednotlivých skupin
 - klasifikační pravidla - vytvořena na základě diskriminační funkce a prior. pravděpodobností; určují jak klasifikovat jev
 - kovarianční matice - určení variability a korelace mezi proměnnými
 - validace modelu - ověření účinnosti na nových nebo nezávislých datech

Princip:

- 1) definice skupin - předdefinovat skupiny, mezi kterými chceme rozlišovat
- 2) výpočet skupinových statistik - pro každou skupinu spočítat průměr a kovarianční matici
- 3) výpočet diskriminační funkce - cílem je najít lineární kombinaci proměnných, která nejlépe oddělí skupiny; to se často dělá pomocí metody, která maximalizuje rozdíl mezi skupinami a minimalizuje rozdíl uvnitř skupin

$$D(x) = a_0 + a_1 x_1 + a_2 x_2 + \dots + a_n x_n$$

$$D(x) = a_1 x_1 + a_2 x_2 + \dots + a_n x_n$$

hodnota disk. fee

a_n - koeficienty

- 4) stanovení klasifikačních pravidel - na základě diskriminační funkce a priorových pravděpodobností se stanoví pravidla pro klasifikaci nových pozorování
- 5) validace modelu - testuje se na nezávislém datasetu, aby se ověřila jeho spolehlivost a přesnost

k čemu to je: forenzní analýzy, identifikace potenciálních zákeřníků, rozlišení zdraví/nemocní pacienti

OBECEĚ LINEÁRNÍ MODEL Y (GLM)

- rodina statistických modelů, které zobecňují klasickou lin. regresi tím, že dovolují predikované proměnné (závislé proměnné) následovat různé statistické distribuce a umožňují systematické komponenty modelu být nelineárními funkcemi nezávislých proměnných
- linková funkce - spojuje střední hodnotu závislé proměnné s lineárním prediktorem
- lineární prediktor - lineární kombinace vstupních proměnných a koeficientů
- distribuce odpovědi - distribuce závislé proměnné (normální, binomická, Poissonova, ...)

základní vzorec

$$g(\mu) = X\beta$$

μ - střední hodnota závislé proměnné

$g(\mu)$ - linková funkce

X - matice (hodnoty nezávislých proměnných)

β - vektor koeficientů

Princip:

- 1) volba distribuce a linkové funkce - před začátkem analýzy je třeba uvést, jaká distribuce a jaká linková funkce budou použity
- 2) odhad koeficientů - metoda max. věrohodnosti
- 3) ověření odhadů - Waldův test, test odstupňované věrohodnosti,...
- 4) predikce a interpretace

k čemu to je: lineární regrese, logistická regrese, Poissonova r.

LINEÁRNÍ REGRESNÍ MODEL

- snaha modelovat vztah mezi 1 nebo více nezávislými proměnnými X a jednou závislou proměnnou Y pomocí lineární funkce

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \varepsilon$$

Y - závislá proměnná

X_n - nezávislá proměnná

β_0 - konstantní člen (intercept)

β_1 - koeficienty nezávislých proměnných

ε - náhodná chyba

- cílem je najít takové hodnoty koeficientů β , které minimalizují sumu čtverců reziduí (RSS), což je rozdíl mezi pozorovanou a predikovanou hodnotou závislé proměnné (nejčastěji pomocí MNC)

NELINEÁRNÍ REGRESNÍ MODEL

$$Y = f(X, \beta) + \varepsilon$$

Y - závislá proměnná

X - vektor nezávislých proměnných

ε - náhodná chyba

f - nelineární funkce parametrizovaná vektorem β

- pro odhad β se používá metoda nejmenších čtverců (MNC) nebo gradientní sestup (SGD)

MNOHONÁSOBNÁ LOGISTICKÁ REGRESE

- umožňuje modelovat pravděpodobnost binárního výsledku na základě více nezávislých proměnných

$$\log\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n$$

p - pravděpodobnost, že závislá proměnná je 1

β - koeficienty, přičemž $\beta_i \geq 0 \rightarrow$ s nárůstem hodnoty X_i se zvyšuje log-odds pravděpodobnosti pozitivního výsledku

VĚCNÁ VÝZNAMNOST

- statistická významnost - měřítko pravděpodobnosti, že pozorovaný efekt v datech je reálný a není pouhým náhodným jevem
- věcná významnost - praktický význam zjištěného efektu
 - zatímco statistická významnost může být dosažena i u malého efektu v případě velkého vzorku, věcná významnost hodnotí, zda je efekt důležitý / užitečný v kontextu zkoumaného problému

Princip:

- statistická významnost sama o sobě nemusí znamenat, že nalezneme praktický význam. Věcná významnost se posuzuje na základě doménové analýzy a interpretace velikosti efektu

METAANALÝZA

- efektová velikost - standardizovaná míra rozdílu nebo souvislosti, která je srovnatelná napříč různými studiemi
- heterogenita - variabilita efektových velikostí napříč studiemi
- fixed-effect model - předpokládá, že efektová velikost je konstantní
- random-effects model - předpokládá, že efekt. velikost může variovat

princip: soubor statistických technik používaných k syntéze výsledků více nezávislých studií na stejné téma. cílem je odhadnout „skutečný“ efekt nebo souvislost, která byla zkoumána v těchto studiích, a určit, jak stabilní a spolehlivý tento efekt je

fixed-effect
$$\hat{\theta} = \frac{\sum_{i=1}^k (w_i \times \theta_i)}{\sum_{i=1}^k w_i}$$

$\hat{\theta}$ - odhadovaná efekt. velikost
 θ_i - efektová vel. i-té studie
 w_i - váha i-té studie

random-effects
$$\hat{\theta} = \frac{\sum_{i=1}^k (w_i^* \times \theta_i)}{\sum_{i=1}^k w_i^*}$$

w_i^* - upravená váha i-té studie

FUZZY LOGIKA

- matematická metoda pro modelování neurčitosti a nejasnosti
- na rozdíl od klasické (Booleany) logiky umožňuje pracovat s celým spektrem pravdivostních hodnot mezi 0 a 1

- Fuzzy set - rozmanitá množina; členství v ní není binární, ale kontinuální (hodnoty např. 0.781)
- Fuzzy variable - rozmanitá proměnná; její hodnota je reprezentována fuzzy setem
- Fuzzy rule - rozmanité pravidlo - logické pravidlo, které mapuje fuzzy proměnné na fuzzy výstup

- (de)fuzzifikace - proces převedení konkrétního čísla na fuzzy a zase zpět na konkrétní číslo

Princip: fuzzy logika je založena na teorii fuzzy setů, kterou vytvořil Lofti Zadeh v roce 1965.

funkce příslušnosti $\mu_A(x)$ - určuje, jak moc je element x příslušný k fuzzy setu A

fuzzy union $A \cup B$

$$\mu_{A \cup B}(x) = \max[\mu_A(x), \mu_B(x)]$$

fuzzy intersection $A \cap B$

$$\mu_{A \cap B}(x) = \min[\mu_A(x), \mu_B(x)]$$

fuzzy complement $\sim A$ $\mu_{\sim A}(x) = 1 - \mu_A(x)$

FUZZY MODELOVÁNÍ

- proces použití fuzzy logiky k vytvoření modelu reálného systému
- FIS - Fuzzy Inference System - využívá fuzzy logiku pro rozhodování nebo predikci

Princip:

- vytvoření fuzzy pravidel, která mapují vstupní fuzzy variables na výstupní fuzzy variables ("połud je rychlost auta vysoká, tak bradna' dráha je dlouhá")

Fuzzy Inference Rule IF x IS A THEN y IS B

- výpočet výstupu y často zahrnuje defuzzifikaci, která může být provedena několika způsoby, např. metodou centroidu

$$y = \frac{\int y \times \mu_B(y) dy}{\int \mu_B(y) dy}$$

POROVNÁNÍ KLASICKÝCH STATISTICKÝCH A BAYESOVSKÝCH METOD

Klasické SM:

- výběrová populace (skutečný / „fixní“ parametr)
- náhodný výběr
- pravděpodobnostní model
- P hodnota (měřítko statistické významnosti)

Testová statistika (Z-test, T-test) $z = \frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{n}}}$

Interval spolehlivosti $CI = \bar{x} \pm z \left(\frac{\sigma}{\sqrt{n}} \right)$

Bayesovské metody

- a posteriori distribuce - zajímáme se o pravděpodobnostní rozdělení parametru, nikoli o jeden skutečný parametr
- apriorní informace - umožňuje zahrnutí apriorního znalostního stavu do analýzy
- pravděpodobnostní model - stejný jako ve statistice, ale P je brána jako míra naší nejistoty

Bayesova věta $P(\theta|D) = \frac{P(D|\theta) \times P(\theta)}{P(D)}$

$P(\theta|D)$ - a posteriori distribuce

$P(\theta)$ - apriorní distribuce

$P(D|\theta)$ - likelihood (pravděpodobnost dat při daném parametru)


$P(D)$ - marginal likelihood (pravděpodobnost dat)

Porovnání

- klasické metody pracují s fixním, ale neznámým parametrem, Bayes. metody s distribucí pravděpodobnosti
- statistická vs. věcná významnost
(p-hodnota) (pomocí apriorního rozdělení)

- komplexnost a výpočetní náročnost - Bayes. výpočetně náročnější

BAYESOVSKÉ SÍTĚ

- grafické modely, které reprezentují pravděpodobnostní vztahy mezi sadou proměnných
- založeny na Bayesově teorii pravděpodobnosti
- umožňují zjistit pravděpodobnostní rozdělení jedné proměnné za podmínky znalosti jedné nebo více dalších proměnných
- uzel (node) - náhodná proměnná
- hrana (edge) - odkazuje na podmíněnou závislost mezi dvěma proměnnými
- parent, children - v dirigovaném acyklickém grafu 
- podmíněná pravděpodobnost - u každého uzlu se ukládá tabulka podmíněných pravděpodobností

Princip:

Bayesovská síť je reprezentována jako dirigovaný acyklický graf, kde každý uzel reprezentuje náhodnou proměnnou, a hrana mezi dvěma uzly označuje podmíněnou závislost. U každého uzlu je uložena tabulka podmíněných pravděpodobností, která ukazuje, jaká je pravděpodobnost stavu této proměnné za různých podmínek jejích „rodíčů“ v síti

Podmíněná pravděpodobnost: $P(A|B) = \frac{P(A \cap B)}{P(B)}$

Základní pravidlo pro Bayesovské sítě

$$P(X_1, X_2, \dots, X_n) = \prod_{i=1}^n P(X_i | \text{Rodiče}(X_i))$$

↑ rodičovské proměnné X_i v Bayes. síti

Bayesova věta v kontextu Bayesovských sítí

$$P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

Rozdíl PCA a FA

PCA

- redukce dimensionality, zachování variability
- identifikace hlavních os (PC), podél kterých data varii
- máme matici dat X o rozměrech $n \times p$, kde n je počet pozorování a p je počet proměnných; k hlavním hodnotám se dostaneme pomocí vlastních vektorů a vlastních hodnot kovarianční matice X

$$\Sigma = \frac{1}{n-1} X^T X$$

$$\Sigma v = \lambda v$$

Σ - kovarianční matice

v - vlastní vektory

λ - vlastní hodnoty

FA

- identifikace skrytých proměnných (faktorů), které vysvětlují korelace mezi pozorovanými proměnnými
- modelování struktury dat, nejen variability
- máme matici dat X , předpokládáme, že $X = LF + \epsilon$
 L - loadings (koeficienty faktor. zatížení), F - faktory, ϵ - chyba

ROZDÍLY: *cíle* PCA - snažit zachovat max. variabilitu dat

FA - snažit identifikovat strukturu v datech

PCA - modeluje celkovou strukturu kovariance

FA - modeluje korelace mezi proměnnými

PCA - ortogonální komponenty, které nejsou korelovány

FA - identifikuje korelované latentní faktory

výstup model.

DISKRIMINAČNÍ ANALÝZA

- určem', jaké proměnné rozlišují mezi 2 a více přirozeně se vyskytujícími skupinami

Lineární DA - používá se, když je výstupní proměnná kategoriální a vstupní proměnné jsou intervalové a normálně rozdělené

Kvadratická DA - pokud myslíme, že skupiny nemají společnou kovarianční matici

Regulární DA - když máme omezený počet pozorování

Implementace:

- 1) předzpracování dat (standardizace, - chybějící hodnoty)
- 2) rozdělení dat (trénink, test)
- 3) výběr proměnných (které jsou relevantní pro klasifikaci)
- 4) vytvoření modelu
- 5) validace modelu
- 6) hodnocení kvality (confusion matrix, accuracy, sensitivity, specificity)

Kritéria hodnocení kvality:

- 1) Přesnost (Accuracy) - % správně klasifikovaných příkladů
- 2) Citlivost (Sensitivity) - schopnost správně identifikovat pozitivní
- 3) Specifita (Specificity) - schopnost správně identifikovat negativní
- 4) F1 skóre - harmonický průběh přesnosti a citlivosti
- 5) ROC křivka - grafické znázornění citlivosti a 1 - specificity
- 6) AUC (Area under curve) - plocha pod ROC, 1 - perfektní model, 0,5 - náhodný model
- 7) Cross-validation

REGRESNÍ ANALÝZA

- metoda používaná k modelování vztahu mezi závislou proměnnou (target) a 1 či více nezávislými proměnnými (features)

GLM (obecné lineární modely)

- rozšíření jednoduchých lin. modelů, které umožňují závislou proměnnou podléhat různým rozdělením (normální, binomické, Poissonovo, ...)

$$g(\mu) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n$$

↑
spojovací
funkce

μ - střední hodnota
závislé proměnné

X_n - nezávislé proměnné
 β_n - parametry modelu

Lin. regresní model : $Y = \beta_0 + \beta_1 X + \varepsilon$

Mnohonásob. lin. regrese : $Y = \beta_0 + \beta_1 X_1 + \dots + \beta_n X_n + \varepsilon$

Nelin. regresní model : $Y = f(X, \beta) + \varepsilon$

Kritéria hodnocení kvality:

- 1) R-kvadrát (Coefficient of Determination) - ukazuje, jaký podíl variability závislé proměnné je vysvětlen modelovými prediktorů
- 2) MSE (Mean Squared Error) - průměr kvadratických rozdílů mezi pozorovanými a predikovanými hodnotami
- 3) RMSE (Root MSE) - druhá odmocnina z MSE
- 4) MAE (Mean Absolute Error) - průměr absolutních rozdílů mezi pozorovanými a predikovanými hodnotami
- 5) F-test - hodnotí, zda jsou všechny regresní koeficienty nulové
- 6) t-test koeficientů - hodnotí, zda jednotlivé koeficienty jsou stat. významné
- 7) AIC, BIC - informační kritéria pro porovnávání kvality různých modelů

MNOHOMĚROBNÁ REGRESE

- zahrnuje více nezávislých proměnných

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon$$

Y - závislá proměnná

β_i - parametry modelu

X_p - nezávislá proměnná

ε - chybový termín

LOGISTICKÁ REGRESE

$$\log\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p$$

p
pravděpodobnost úspěchu

ROC ANALÝZA

- Receiver Operating Characteristic

- nástroj pro hodnocení kvality binárního klasifikátoru

- znázorňuje vztah mezi citivostí (TPR) a 1-specificitou (FPR)

