

# Obecné lineární modely, lineární a nelineární regresní modely. Mnohonásobná a logistická regrese

Sergii Babichev

Univerzita Jana Evangelisty Purkyně v Ústí nad Labem

*[sergii.babichev@ujep.cz](mailto:sergii.babichev@ujep.cz)*

# Regresní analýza

Spojité veličiny

$$y = ax + b + \epsilon$$



$\epsilon$   
↑  
chyba

lineární  $y = 5x$

polynomiální  $y = 5x^2$

Závislost mezi kvantitativními proměnnými X a Y:

- Funkční závislost – hodnotami nezávisle proměnných je jednoznačně dána hodnota závislé proměnné:  $Y=f(X)$
- Stochastická (volná) závislost – systematický pohyb jedné veličiny při růstu či poklesu druhé veličiny



Regrese – snaha aproximovat body  
májit závislost a odhadnout koeficienty

# Regresní analýza

*Korelace - jsou veličiny závislé? jak moc?  
regrese - dej mi data, dej mi nezávislé proměnné,  
já ti vrátím odhad závislých proměnných.*

## Korelační a regresní analýza

Vyhodnocují vztah mezi spojitými veličinami:

- Nekauzální vztahy (neznáme příčinu a důsledek) – korelační analýza;
- Kauzální vztahy (víme co je příčina a co je následek) – korelační i regresní analýza.

**Nezávisle** proměnná (**vysvětlující** proměnná) – vysvětluje chování závislé proměnné (příčina);

**Závisle** proměnná (**vysvětlovaná** proměnná) – proměnná jejíž chování se snažíme vysvětlit (následek)

## Typy regrese

- Jednoduchá regrese - studuje kauzální závislost dvou veličin (velikost syna na velikosti otce); *jen x*
- Vícenásobná regrese - studuje kauzální závislost jedné veličiny na alespoň dvou dalších veličinách (velikost syna na velikosti otce a matky). *více proměnných*

*lineární regrese*

## Typy regrese

- Polynomiální regrese. Základem tohoto modelu je polynomiální funkce:


$$y = b_0 + b_1x + b_2x^2 + b_3x^3 + \dots + b_nx^n + \varepsilon$$

- Nelineární regrese. Tento typ modelu je založen na jiném typu funkce s jedním nebo více parametry (například  $y = ae^{bx}$ ).
- Logistická regrese. Tento typ modelu se používá pro simulaci pravděpodobnosti existence určité třídy nebo události. Každé detekované události by byla přiřazena pravděpodobnost mezi 0 a 1 a součet všech pravděpodobností by v tomto případě měl být roven jedné.

# Regresní analýza = metoda nejmenších čtverců

cíl je minimalizovat  $\sum e_i^2 = \sum (y_i - \hat{y}_i)^2$   
chyby

## Korelační pole



## Jednoduchý lineární regresní model

Vyrovňovací křivka:

$$Y_i = \beta_0 + \beta_1 x_i + e_i$$

*Handwritten notes above the equation:*  
A red bracket above  $\beta_0$  and  $\beta_1$  is labeled "náhodně" (randomly).  
Below  $\beta_0$  is the handwritten label  $b_0$ .  
Below  $\beta_1$  is the handwritten label  $b_1$ .

Parametry modelu  
*skutečné hodnoty*


Reziduum  
Náhodná složka –  
popisuje vliv  
náhodných nebo  
nepozorovaných  
regresorů a vliv  
náhody

Výška otce **Vysvětlující (nezávisle) proměnná**

## Jednoduchý lineární regresní model



a) Scatter plot of two-dimensional data



b) Fitted line of a simple regression model

*metoda nejmenších čtverců*

## Jednoduchý lineární regresní model

Kritériem "nejlepší" funkční predikce je minimalizace součtu čtverců odchylek empirických hodnot  $y$  od teoretických hodnot získaných regresní rovnicí  $Y$ :

$$S(a, b) = \sum_{i=1}^n (Y_i - y_i)^2 = \sum_{i=1}^n (a + bx_i - y_i)^2 \rightarrow \min$$

$$\frac{\partial S}{\partial a} = 2 \sum_{i=1}^n (a + bx_i - y_i) = 0; \quad \frac{\partial S}{\partial b} = 2 \sum_{i=1}^n (a + bx_i - y_i)x_i = 0$$


$$na + b \sum_{i=1}^n x_i = \sum_{i=1}^n y_i; \quad a \sum_{i=1}^n x_i + b \sum_{i=1}^n x_i^2 = \sum_{i=1}^n y_i x_i$$

$$b = \frac{n \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \cdot \sum_{i=1}^n y_i}{n \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2}; \quad a = \frac{\sum_{i=1}^n y_i \cdot \sum_{i=1}^n x_i^2 - \sum_{i=1}^n x_i \cdot \sum_{i=1}^n x_i y_i}{n \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2}.$$

## Model lineární polynomiální regrese - *přidáváme mocniny*

Polynomiální regrese je regresní model, který je lineární v parametrech, ale popisuje nelineární závislost mezi proměnnými podle rovnice:

$$y = b_0 + b_1x + b_2x^2 + b_3x^3 + \dots + b_nx^n + \varepsilon$$



## Model lineární polynomiální regrese

Množinu koeficientů  $b_i$  lze také nalézt na základě metody nejmenších čtverců:

$$S(b_0, b_1, \dots, b_k) = \sum_{i=1}^n (y_i - b_0 - b_1 x_i - \dots - b_k x_i^k)^2 \rightarrow \min$$

$$\frac{\partial S(b_0, b_1, \dots, b_k)}{\partial b_j} = 0, \quad j = 1 \dots k$$

$$2 \cdot \sum_{i=1}^n (y_i - b_0 - b_1 x_i - \dots - b_k x_i^k) \cdot (-1) = 0$$

$$2 \cdot \sum_{i=1}^n (y_i - b_0 - b_1 x_i - \dots - b_k x_i^k) \cdot (-x_i) = 0$$

.....

$$2 \cdot \sum_{i=1}^n (y_i - b_0 - b_1 x_i - \dots - b_k x_i^k) \cdot (-x_i^k) = 0$$

# Regresní analýza

- pořadí se bojíme v spojitych veličinách

Nelineární regresní model - už to jen nesčítám jako u lin.

Nelineární regrese je regrese, ve které jsou závislé nebo kritériální proměnné modelovány jako nelineární funkce parametrů modelu a jedné nebo více nezávislých proměnných. Nelineární regrese používá nelineární regresní rovnice, které mají tvar:


$$Y = f(X, \beta) + \varepsilon,$$

kde:  $X$  je vektor  $p$  <sup>proměnné</sup> prediktorů;  $\beta$  je vektor  $k$  parametrů;  $f(\cdot)$  je známá regresní funkce;  $\varepsilon$  je chybový termín. Jako regresní lze použít následující funkce:


- asymptotická funkce 1:  $y = \frac{ax}{1 + bx}$ ;
- asymptotická funkce 2:  $y = a(1 - \exp(-bx))$ ;
- hyperbolická funkce:  $y = a + \frac{b}{x}$ ;
- logistická funkce:  $y = \frac{1}{a + b \cdot \exp(-x)}$ .

## Nelineární regresní model


a) Asymptotic function 1




b) Asymptotic function 2



c) Hyperbolic function



d) Logistic function



$\times \neq 0$

pravděpodob.  
funkce  
(0;1)

# Regresní analýza

- více funkcí  
x, y vysvětlujeme na základě vícero veličin

## Mnohonásobná regrese

Jestliže máme jednu vysvětlovanou a několik vysvětlujících proměnných, pro analýzu jejich vztahu používáme mnohonásobnou lineární nebo nelineární regresi:

$$Y = b_0 + b_1x_1 + b_2x_2 + \dots + b_kx_k$$

$$Y = b_0 + b_1f_1(x_1) + b_2f_2(x_2) + \dots + b_kf_k(x_k)$$

Cílem analýzy je stanovit hodnoty parciálních regresních koeficientů  $b_i$  pro každou vysvětlující proměnnou. Jejich kombinace pak vytváří regresní rovnici.

$b_0 \rightarrow$  pokud  $b$  jsou 0, pak  $y = b_0$

intercept = absolutní člen  $\Rightarrow y = b_0$

$b_1$  - hodnota  $y$  se zvýší o  $b_1$  (v průměru, pokud  $x_1$  se zvýší o 1)


# Regresní analýza

1) pomocí veličin co nejlépe odhadnout  $Y$   
snížit rozptyl chybových členů

- výsledkem této regrese není pouze přímka, ale hodně odhadů  
(menší se  $y$  abs. hod. chybové členy)

## Postupy pro vytvoření mnohonásobné regrese:

- 1) vysvětlit rozptyl v závisle proměnné  $Y$ ;
- 2) odhadnout (vypočítat) vliv každé z nezávisle proměnných  $x$  na proměnnou závislou. Sílu tohoto vlivu sdělují nestandardizované regresní koeficienty  $b_j$ . Vliv každé nezávisle proměnné je odhadován tak, že je kontrolováno působení ostatních nezávisle proměnných, které vstupují do modelu. Mnohonásobná regrese prostřednictvím standardizovaných regresních koeficientů ( $b_j$ ) také pomáhá určit relativní sílu vlivu jednotlivých proměnných na proměnnou závislou – my tak zjistíme, které proměnné mají na rozptyl závisle proměnné největší vliv a které mají naopak vliv nejmenší;
- 3) s pomocí sestavené regresní rovnice predikovat pro jednotlivé případy hodnoty závisle proměnné.




1)  $H_0 : b_1 = 0$   
 2)  $H_0 : b_1 = 0$   
 $p < \alpha = 0,05$

-  $p > t$  - hodně malé číslo  
 -  $\star$  - čím více hvězdiček, tím víc člen OK

## Logistická regrese

Logistická regrese je označení metody matematické statistiky zabývající se problematikou odhadu pravděpodobností nějakého jevu (závisle proměnné) na základě určitých známých skutečností (nezávisle proměnných), které mohou ovlivnit výskyt jevu.

$p$  = pravděpodobnost veličiny Matematický model



$$y = \ln \frac{p}{1-p}$$

$$y = b_0 + b_1x_1 + \dots + b_nx_n$$

$$\ln \frac{p}{1-p} = b_0 + b_1x_1 + \dots + b_nx_n$$

$$\frac{p}{1-p} = \exp(b_0 + b_1x_1 + \dots + b_nx_n)$$

$$p = \frac{1}{1 + \exp(-(b_0 + b_1x_1 + \dots + b_nx_n))}$$

## Metody hodnocení kvality regresního modelu

Metody pro odhad kvality regresního modelu jsou založeny na následujících technikách:

- analýza zbytků;
- determinační koeficient (R Squared);
- Akaike informační kritérium (AIC);
- Bayesovské informační kritérium (BIC);
- Kvantilé-quantilé (Q-Q) graf;
- Analýza ROC (Receiver Operating Characteristic).

*residuální - (porovnat  $Y$  a  $y_1$  - jak je to vadaření?)*

## Metody hodnocení kvality regresního modelu

- Zbytkový součet čtverců (residual sum of squares - RSS), také známý jako součet čtverců reziduí (SSR) nebo součet čtverců chyb (SSE), je součtem čtverců reziduí (odchylky předpovězené od skutečných empirických hodnot dat):

*reziduální*  
*součet čtverců*

$$RSS = \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

kde  $y_i$  je i-tá hodnota proměnné, která má být predikována,  $\hat{y}_i$  je i-tá predikovaná hodnota.

Je to míra nesouladu mezi daty a modelem odhadu. Je zřejmé, že menší hodnota RSS ukazuje na těsnější přizpůsobení modelu empirickým datům.

*$\hat{y}$  - vyrovnané hodnoty (co vypadne z modelu) - predikovaná*  
 *$y$  - naměřená data*       *$\bar{y}$  - průměr pozorování*

## Metody hodnocení kvality regresního modelu

- Koeficient determinace (R-squared) je podíl rozptylu v závislé proměnné, který je předvídatelný z nezávislé proměnné (proměnných). V regresní analýze existují tři definice součtů čtverců:
  - Celkový součet čtverců (úměrný rozptylu dat):

$$SS_{tot} = \sum_{i=1}^n (\bar{y} - y_i)^2$$

kde  $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$  je průměr empirických hodnot.

- Regresní součet čtverců se také nazývá vysvětlený součet čtverců:

$$SS_{reg} = \sum_{i=1}^n (\bar{y} - \tilde{y})^2$$

kde  $\tilde{y} = \frac{1}{n} \sum_{i=1}^n \hat{y}_i$  je průměr předpovídaných hodnot.

- Zbytkový součet čtverců:

$$SS_{res} = \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

## Metody hodnocení kvality regresního modelu

- Koeficient determinace  $R^2$  je definován jako poměr regresního součtu čtverců k celkovému součtu čtverců:

$$R^2 = \frac{SS_{reg}}{SS_{tot}} = 1 - \frac{SS_{res}}{SS_{tot}}$$

Hodnoty determinačního koeficientu se mění v rozsahu  $< 0, 1 >$ .

Koeficient determinace umožňuje odhadnout část rozptylu závislé proměnné  $Y$ , kterou lze vyjádřit regresní funkcí.

## Metody hodnocení kvality regresního modelu

- Akaike informační kritérium (AIC) je odhadem relativní kvality statistických modelů pro daný soubor dat. S ohledem na soubor modelů pro data odhaduje AIC kvalitu každého modelu ve vztahu ke každému z ostatních modelů. AIC tedy poskytuje prostředek pro výběr modelu. Předpokládejme, že máme statistický model nějakých dat. Nechť  $k$  je počet odhadovaných parametrů v modelu a  $\hat{L}$  je maximální hodnota věrohodnostní funkce pro model. Hodnota AIC modelu vypočítá takto:

$$AIC = 2k - 2\ln(\hat{L})$$

V tomto případě je preferován model s minimální hodnotou AIC.

## Metody hodnocení kvality regresního modelu


- Bayesovské informační kritérium (BIC) je také kritériem pro výběr modelu mezi konečnou množinou modelů. Upřednostňuje se model s nejnižším BIC. Je založeno částečně na věrohodnostní funkci a úzce souvisí s informačním kritériem Akaike (AIC). BIC je formálně definován takto:

$$BIC = k \cdot \ln(n) - 2\ln(\hat{L})$$

kde  $n$  je počet pozorování.


- Kvantilový kvantilový (Q-Q) graf je grafem reziduí versus očekávané řádové statistiky standardního normálního rozdělení. Tento typ grafu se nazývá graf Q-Q, protože vykresluje kvantily dat versus kvantily distribuce. Pokud jsou obě porovnávaná rozdělení podobná, budou body v grafu Q-Q přibližně ležet na přímce  $y = x$ . Pokud jsou distribuce lineárně vztaženy, body v grafu Q-Q budou přibližně ležet na přímce, ale ne nutně na přímce  $y = x$ .

## ROC křivka (receiver operating characteristic)



## ROC křivka (receiver operating characteristic)

$$ROC : senc = f(1 - spec)$$



## Vytvořte model lineární regrese

- 1 Načtěte data ze souborů: *simplreg.txt* a *fruitohms.txt*. Vizualizujte závislosti  $Y = F(X)$  v prvním případě a  $juice = F(ohms)$  ve druhém případě pomocí bodového grafu. Uložte grafy jako soubor *png* ve dvou oknech (1 řádek a 2 sloupce).
- 2 Vytvořte lineární jednoduchý a polynomiální regresní model pro načtená data. Zvyšte stupeň polynomu z 2 na .... Vypočítejte kritéria kvality (R-Squared, AIC, BIC) v každém z případů. Vytvořte 1 řádkový a 3 sloupcový graf kritérií kvality versus stupeň polynomu pro každé z dat. Uložte grafy jako soubory *png*. Vyberte nejlepší modely pro každé z údajů z hlediska použitých kritérií.
- 3 Vizualizujte výsledky ve dvou řádcích a dvou sloupcích pomocí normálního Q-Q grafu pro rezidua a přidáním regresní čáry k bodovému grafu červenou barvou. Uložte grafy jako soubor *png*.

ověřen  
pochází z normálního rozdělení?  
data

## Vytvořte nelineární regresní model

- 1 Načtěte data *misrala* a *BoxBOD*. Vizualizujte datové sady pomocí bodového grafu.
- 2 Vytvořte polynomiální a nelineární regresní modely. Funkce nelineární regrese je následující:  $y = a(1 - e^{(-bx)}) + \varepsilon$ . Porovnejte získané modely podle kvalitativních kritérií a normálního Q-Q grafu.
- 3 Vizualizujte získané výsledky: grafy získaných modelů a normální Q-Q grafy. Uložte grafy jako soubory *png*.

## Vytvořte vícenásobný regresní model

- Načtěte data *longley* (*datasets* package) a data *auto-mpg*.
- Transformujte data *longley* následujícím způsobem:  

```
vars <- c("Employed", "GNP.deflator", "GNP", "Unemployed",  
"Armed.Forces", "Population")  
mydata <- longley[, vars]
```
- Vizualizujte data pomocí *scatterplotMatrix* (package *car*). Uložte grafy jako soubor *png*.
- Analyzujte data pomocí korelační analýzy.
- Vytvořte vícenásobný regresní model. *Employed* proměnná je výstupní. Procházejte různé typy závislostí, vyberte nejlepší model z hlediska kritérií kvality a normální graf Q-Q pro rezidua. Uložte konečnou verzi grafu Q-Q jako soubor *png*.
- Konečný výsledek prezentujte jako regresní model s číselnými koeficienty.

## Vytvořte model logistické regrese

- Načtěte data *sex2* (*logistf* package).
- Vytvořte následující modely logistické regrese:  
$$case = F(age, oc, vic, vicl, vis, dia)$$
$$case = F(age, vic, vicl)$$
- Porovnejte získané modely pomocí ROC analýzy. Ve každém případě spočítejte accuracy. Vytvořte ROC křivku v jednom okně. Uložte tento graf jako soubor png.