

Logistická regrese

- algoritmus ML používaný pro klasifikaci
- užitečná, když je cílová proměnná binární (1/0)
- snaha najít nejlepší možnou rozhodovací hranici, která oddělí třídy v datovém prostoru
- matematicky je využívána logistická funkce (sigmoidní) k převodu lineární kombinace vstupních proměnných na hodnotu mezi 0 a 1. Tato hodnota pak slouží jako pravděpodobnost k příslušnosti k jedné z tříd
- výstupem modelu je pravděpodobnost, která je následně porovnávána s prahovou hodnotou (0,5) k určení třídy (1/0)

vrzorec:

$$a = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + b$$

w - váhy spojené s každým vstupem x

$$\sigma(a) = \frac{1}{1 + e^{-a}}$$

↑
bias

↑
výstupní hodnota
(0-1)

↙ odhadovaná P , že vzorek patří do (+) třídy

predikce $\hat{y} = \sigma(a)$

$$J(w, b) = -\frac{1}{m} \sum_{i=1}^m [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

↑
hodnota fee,
kterou chceme
minimalizovat

m - počet vzorků
v datasetu

y_i - skutečná třída i vzorku
 $\hat{y}_i$ - predikovaná P , že y_i patří
do 1 ($\rightarrow$ log. fee)

- snaha maleřit takové hodnoty w, b , které minimalizují $J(w, b)$ pomocí optimalizačních metod (např. gradient decrease)

Vícevrstvý perceptron (MLP)

- log regrese využívá lineární kombinaci vstupních proměnných + log fee.

- MLP rozšiřuje do více vrstev a více neuronových jednotkami a nelineárními aktivními funkcemi - 1
- rovnice $w_1 x_1 + w_2 x_2 + b = +1$ je formou rozhodovací hranice jednoduchého perceptronu. (vzor je určen pro lineárně separovatelné problémy)

$$\hat{y} = \text{sign}(w^T \cdot x + b)$$

sign - funkce znaménka, která vrátí +1 / -1

$\hat{y}$ - predikovaná třída vzorku (+1, -1/0)


w - vektor vah (určuje, jak každá vstupní hodnota ovlivňuje výstup)

w^T - transpozice vektoru w (skalární součin $w \cdot x$)

x - vstupní vektor

b - bias, konkrétní hodnota, která posouvá rozhodovací hranici

jednoduchý perceptron



inputs | weights | summation + bias | activation | output
data

- sečte jednotlivé informace ze vstupu a tím, že každému vstupu dá nějakou váhu a na základě toho se určí výstup
- výstup je dán aktivací funkcí (ade jednotkový skok)
- ztrátová fce v případě perceptronu je **LOSS FUNCTION**

$$J(w) = \sum_i \max(0, -y_i \cdot w^T \cdot x_i)$$

- pokud $y_i = 1$ a $w^T \cdot x_i \geq 0$ (příklad je klasifikován správně) pak argument funkce max je záporný 0 (nedochází k načítání)

- $y_i = -1, w^T x_i \leq 0$ (taký nedochází k načítání hodnot)
- minimalizace ztrátové funkce - metoda největšího spádu (LGD)

V případě perceptronu je přechod mezi třídami skokový, protože aktivací funkce není spojitá

→ logistická regrese používá jako aktivací funkci sigmoidu
 $s(x) = \frac{1}{1+e^{-x}}$, která udává pravděpodobnost příslušnosti do dané třídy, protože obor hodnot $H_s = (0;1)$

výsledná predikce je $\hat{y} = \frac{1}{1+e^{-wx}}$

w - vektor vah

x - příslušný bod

$w \cdot x = \sum_k w_k x_k$ (skalární součin)

— logistická regrese je v případě komplexních modelů náchylná k přecpávání (nefunguje dobře na testovacích datech), při učení došlo k minimalizaci ztrátové funkce, ale nebyly zachyceny podstatné rysy pro rozhodnutí
 → proto se přidávají penalty (regularizace)

— metoda podpůrných vektorů

