


Lineární regrese




k čemu je přínos

R^2 - říkají, jestli váha a velikost koreluje (velké hodnoty naznačují velký efekt)

spočítej hodnotu r → je R^2 statisticky významné?

predikuj velikost na základě váhy

Vícenásobná regrese




- predikce velikosti podle váhy a objemu (modelace)

- vícenásob. regrese dělá to same jako lin., ale lépe (více parametrů)

- dobře ponovnávat modely

Logistická regrese

- predikuje, jestli je pozorovaný jev True / False



- pokud je $P \geq 50\%$ → TRUE

- model může mít mnoho parametrů

- rozdíl oproti lin. regresi - způsob, jakým je funkce daná do dat

metoda ↙ nejmenších $\square$

(line that minimizes the sum of the squares of the residuals)

log. regrese → max. pravděpodobnost

jak se hádá podle toho, ose x, tak hádá podle toho, ose y (sigmoida)

GENERALIZOVANÉ LIN. MODELÝ (GLM)

logistická regrese
 lineární modely - nelimitujeme rovnici na určitý Df → jednodušší řešení

KOEFICIENTY


CONTINUOUS VARIABLES

log. reg.

$p \in (0,1)$

$$\log\left(\frac{p}{1-p}\right)$$

$p=1 \rightarrow \log\left(\frac{1}{1-1}\right) \rightarrow \log(1) - \log(0) = +\infty$



$$y = -3.48 + 1.83 \cdot \text{váha}$$

průsečík s y
pokud váha=0



standardní
odchylka



očíslovaný průsečík
odchylka

	ESTIMATE	STD. ERROR	Z-VALUE
(INTERCEPT)	-3,476	2,364	-1,471

DISCRETE VARIABLES (souvisí spolu 2 veličiny?)
 např. genóm a obezita

nemusi být lineární





$$w_1 x_1 + u_2 y_2 + b = +1$$

$$w_1 x_1 + u_2 x_2 + b = -1$$


$$\bar{x} \begin{vmatrix} y \\ +1 \\ -y \end{vmatrix}$$

$10^4 \downarrow$

$$w^{-T} \bar{x} + b = y$$

chyba


$$\sum (y_i - \hat{y}(x_i))^2$$



sigmoída
(log. reg.)
f(x)


Co je strojové učení?

→ generalizace na základě zkušeností
(klasifikační úloha)



nejspíš to bude hrůška,
ale potřebujeme příklady


→ cílem ML je



Učím ML je
nalezt hranici

vlastnostem se říká atributy (může jich být hodně)
hranice nemusí být lineární funkce!

Regresní analýza



jak určit funkci?
(podle funkce můžeme predikovat)

(křížky)


$$\text{DATA} = \{(s_1, c_1), (s_2, c_2), (s_3, c_3), \dots, (s_n, c_n)\}$$

$$f(s) = as + b$$

- zjednodušit problém,
najít lin. fci (s je náš
parametr, a a b jsou param.
té lin. fce)

chceme, aby nalezená
funkce měla minimální chybu - součet vzdáleností
bodů od naší funkce

(nejkratší by byla kolmá, ale skutečná vzdálenost je to druhé)



chyba

$$e = \sum_{i=0}^n (c_i - f(s_i))^2$$

rozdíl skutečné ceny a funkční hodnoty modelu
můžeme také lineárně

- pokud by bylo $f(s_i) > c_i$, tak to nebude funkční
- proto abs. hodnota nebo mocnina
- ! a pak nepočítáme součet vzdáleností, ale čtverců!
- musíme derivovat a kvadratická fce se derivuje líp
- pokud budeme minimalizovat naši funkci, tak se dá ukeřsat, že body se chovají jako by byly z normálního rozdělení se střední hodnotou v té funkci hodnotě
- Chceme najít takovou funkci $f(s)$, aby měla vůči našim datům tu chybu MINIMÁLNÍ


$$e = \sum_{i=1}^m (c_i - f(s_i))^2 = \sum_{i=1}^m (c_i - [a]s_i + [b])^2$$

takže vlastně hledáme parametry a, b tak, aby chyba byla minimální

"vzestevnice, které analyzují chybu naší funkce" vůči datům

jak zjistit, jak na tom parametry jsou?

~~napi. náhodně zvolit~~



spočítat gradient, protože chceme nalézt ty parametry s min. chybou

gradient - vektor, který směřuje ve směru "nej. stoupání", ale my potřebujeme opačně (dostat se do údolí) nejstrmější cestou

STEEPEST GRADIENT DESCENT (SGD)

- vybereme nejstrmější, ale obrátíme ho
- iterativní algoritmus

MATEMATICKY - máme a_0, b_0 , chceme a_1, b_1 a krok

se

$$a_1 = a_0 - \lambda \frac{\partial e}{\partial a}$$

$$b_1 = b_0 - \lambda \frac{\partial e}{\partial b}$$

chceme řídit
velikost kroku,
tak to vynásobíme
parametrem lambda

parciální derivace
chyby e podle par. a

že jsme došli do minima parametrem podle toho, že
derivace jsou nulové


co když minimum není jen jedno? (např. je jedno lokální
a jedno globální)

pokud použijeme lineární funkci a kvadratickou chybu,
tak se nám to nestane a minimum je právě jedno

Logistická regrese

regresní úloha - na základě vstupních dat predikovat
číselnou hodnotu

klasifikace - predikovat 1+ tříd



$$f(x) = ax + b$$

hledám hranici, která mi rozdělí
jablka a hrušky


bromě rozhodnutí hruška ano/ne
chci "míru hruškovitosti"

čím větší hodnota na ose hruškovitosti,
tím spíše je to hruška

např. lineární funkce, která prochází
0 hodnotou v hranici

(záleží i na sklonu)

→ lepší je predikovat pravděpodobnost, že je to hruška






$$D_f (-\infty, +\infty)$$

$$H_f (0, 1)$$


g - logistická funkce

$$g(x) = \frac{1}{1 + e^{-x}} \Rightarrow \frac{1}{1 + e^{-(ax+b)}}$$

- za předpokladu, že známe parametry a, b (ta lin. fce),
tak pro libovolnou vlastnost dokážeme spočítat její pravděpodobnost
jako spočítat a, b ?



$$f(x_1) = x_1 w_1 + w_0$$



$$f(x_1, x_2) = w_1 x_1 + w_2 x_2 + w_0$$

$$f(\vec{x}) = \vec{w} \vec{x} + w_0$$

↑
vektor, protože
porovnává vstupních
parametrů

↑
posun

→ výstupní hodnota je
řádky skalár (číslo)

$$g(\vec{x}) = \frac{1}{1 + e^{-(\vec{w} \vec{x} + w_0)}}$$

nutno najít $\vec{w}$ a w_0 ,
ty určují, kde bude rovina

... najít parametry

naše účelem není najít parametr takové, aby chyba toho klasifikátoru byla co nejmenší
 brusky = 1, jablka = 0, takže $g(\vec{x})$ bude vracet (0; 1)
 jak určit chybu?

	y	$g(\vec{x})$
1	0	0,1
2	1	0,9
3	1	0,8
4	0	0,2

↑ skutečné hodnoty
 ↑ predikované hodnoty


(nemůžeme použít stejný postup jako u lin. regrese, protože bychom měli víc lokálních minim)

→ používá se CROSS ENTROPY


$$l_i = \begin{cases} y_i = 1 & -\log(q(\vec{x})) \\ y_i = 0 & -\log(1 - q(\vec{x})) \end{cases}$$

- silná penalizace opačných predikcí

- sase pak na hledání parametrů lze použít SGD



- logistická regrese většinou rozděljuje do 2 tříd
 ale i více tříd



3 klasifikátory

→ vybírá ten, který vrátí největší pravděpodobnost

Zbroslení a rozptyl

- model generovaný z dat $f_D(x)$ je statistickým odhadem $f(x)$
- odhad je vždy zatížen sbroslením (bias) a rozptylem (Variance)


bias - pokud natrénujeme model $f_D(x)$ na mnoha datasetech D , reprezentuje bias očekávanou odchylku mezi predikcí a skutečnou hodnotou $B = E[f_D(x) - y] \quad (E)$

rozptyl - V reprezentuje rozptyly jednotlivých odhadů

$$V = E[(f_D(x) - \bar{f}(x))^2]$$

průměrná predikce x

- složitější modely (mnoho parametrů) - nižší sbroslení, větší rozptyl
- jednodušší modely - vyšší bias, nižší rozptyl



polynom odpovídá jednotlivým vzorkům, ne celé množině, jeho tvar se může lišit vzorek od vzorku ($\uparrow$ rozptyl)
pouze přímka, pokud máme jednoduchý lin. model

celková očekávaná chyba $B^2 + V$

